데이터 분석(Python / R)

2일차:데이터 다루기(NumPy, Pandas)

삼성전자공과대학교 3학년 3학기

Python example

```
import random
class Die(object):
    def __init__(self):
        self.sides = 6
    def set_sides(self, sides_change):
        if sides_change >= 4:
            if sides_change != 6:
                print("change sides from 6 to ", sides_change, " !")
            else:
                print("sides set to 6")
            self.sides = sides change
        else:
            print("wrong sides! sides set to 6")
    def roll(self):
        return random.randint(1, self.sides)
if __name__ == '__main__':
   d = Die()
    d1 = Die()
    d.set sides(4)
    d1.set_sides(4)
    print(d.roll(), d1.roll())
```

Python types


☐ Numeric Types	
☐ integers	
☐ floats	
complex numbers	
☐ Booleans	
☐ Sequence Types	
☐ list	
☐ tuple	
☐ Text Sequence Types	
☐ string	

☐ Set Types	
□ set	
☐ frozenset	
Mapping Types	
☐ dictionary	

Mutable	Immutable
list	tuple
set	frozenset
dictionary	string
byte array	bytes


Numpy

■ ndarray : 같은 type을 가지는 데이터들의 N 차원 배열



- Multi-dimensional arrays
- Built-in array operations
- Simplified, but powerful array interactions -> broadcasting
- Integration of other languages (Fortran, C, C++)

Numpy – ecosystem



Numpy -기초

```
>>> import numpy as np
>>> a = np.array([1,2,3,4,5,6,7,8,9])
>>> a
array([1, 2, 3, 4, 5, 6, 7, 8, 9])
>>> b = a.reshape((3,3))
>>> b
array([[1, 2, 3],
[4, 5, 6],
[7, 8, 9]])
>>> b * 10 + 4
array([[14, 24, 34],
[44, 54, 64],
[74, 84, 94]])
```

List

```
>>> a = [1,3,5,7,9]

>>> b = [3,5,6,7,9]

>>> a + b

[1, 3, 5, 7, 9, 3, 5, 6, 7, 9]
```

numpy array

```
>>> a = np.array([1,3,5,7,9])

>>> b = np.array([3,5,6,7,9])

>>> a + b

array([4, 8, 11, 14, 18])
```

Numpy - 생성

Vector

```
# as vectors from lists
>>> a = np.array([1,3,5,7,9])
>>> b = np.array([3,5,6,7,9])
>>> c = a + b
>>> c
[4, 8, 11, 14, 18]

>>> type(c)
(<type 'numpy.ndarray'>)

>>> c.shape
(5,)
```


One type

```
>>> M[0,0] = "hello"
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
ValueError: invalid literal for long()
with base 10: 'hello'
```

Matrix

```
>>> 1 = [[1, 2, 3], [3, 6, 9], [2, 4, 6]]
>>> a = np.array(1)
>>> a
[[1 2 3]
[3 6 9]
 [2 4 6]]
>>> a.shape
(3, 3)
>>> a.dtype
int64
>>> M = np.array([[1, 2], [3, 4]])
>>> M.shape
(2, 2)
>>> M.dtype
dtype('int64')
# 타입 지정
>>> M = numpy.array([[1, 2], [3, 4]], dtype=complex)
>>> M
array([[1.+0.j, 2.+0.j],
      [3.+0.j, 4.+0.j]
```

Numpy - slicing



Numpy - slicing

```
>>> print(a)
[[1 2 3]
[3 6 9]
[2 4 6]]
>>> print(a[0]) # 리스트와 동일하게 동작
[1 2 3]
>>> print(a[1, 2]) # row, column
9
>>> print(a[1, 1:3])
[6 9]
>>> print(a[:,1])
[2 6 4]
>>> a[1, 2] = 7
>>> print(a)
[[1 2 3]
[3 6 7]
[2 4 6]]
>>> a[:, 0] = [0, 9, 8]
>>> print(a)
[[0 2 3]
[9 6 7]
 [8 4 6]]
```

Numpy - 생성함수

```
>>> x = arange(0, 10, 1) # start, stop, step
>>> x
array([0, 1, 2, 3, 4, 5, 6, 7, 8, 9])
>>> np.linspace(0, 10, 25)
array([ 0. , 0.41666667, 0.83333333, 1.25 ,
       1.66666667, 2.08333333, 2.5 , 2.91666667,
       3.33333333, 3.75 , 4.16666667, 4.58333333,
       5. 5.41666667, 5.83333333, 6.25
       6.66666667, 7.083333333, 7.5 , 7.91666667,
       8.33333333, 8.75 , 9.16666667, 9.58333333, 10.
>>> np.logspace(0, 10, 10, base=numpy.e)
array([ 1.0000000e+00, 3.03773178e+00, 9.22781435e+00,
       2.80316249e+01, 8.51525577e+01, 2.58670631e+02,
       7.85771994e+02, 2.38696456e+03, 7.25095809e+03,
       2.20264658e+04])
```

Numpy - 생성함수

```
# 대각 행렬
>>> np.diag([1,2,3])
array([[1, 0, 0],
      [0, 2, 0],
      [0, 0, 3]])
>>> b = np.zeros(5)
>>> print(b)
[ 0. 0. 0. 0. 0.]
>>> b.dtype
dtype('float64')
>>> n = 1000
>>> my int array = np.zeros(n, dtype=np.int)
>>> my int array.dtype
dtype('int32')
>>> c = numpy.ones((3,3))
>>> c
array([[ 1., 1., 1.],
      [ 1., 1., 1.],
      [ 1., 1., 1.]])
```

Numpy - array사용

```
>>> d = numpy.arange(5)
>>> print(d)
[0 1 2 3 4]
>>> d[1] = 9.7
>>> print(d) # 기존 type 보존
[0 9 2 3 4]
>>> print(d*0.4) # 연산을 수행하면 새로운 array 생성(type은 결과에 맞게 변경)
[ 0. 3.6 0.8 1.2 1.6]
>>> d = np.arange(5, dtype=np.float)
>>> print(d)
[ 0. 1. 2. 3. 4.]
>>> np.arange(3, 7, 0.5) # type
array([ 3. , 3.5, 4. , 4.5, 5. , 5.5, 6. , 6.5])
```

Numpy - array사용

```
>>> np.mgrid[0:5, 0:5] # meshgrid 생성
array([[0, 0, 0, 0, 0],
     [1, 1, 1, 1, 1],
     [2, 2, 2, 2, 2],
     [3, 3, 3, 3, 3],
      [4, 4, 4, 4, 4]]
array([[0, 1, 2, 3, 4],
     [0, 1, 2, 3, 4],
     [0, 1, 2, 3, 4],
     [0, 1, 2, 3, 4],
      [0, 1, 2, 3, 4]])
# random data
>>> mp.random.rand(5,5)
array([[ 0.51531133, 0.74085206, 0.99570623, 0.97064334, 0.5819413 ],
      [ 0.2105685 , 0.86289893 , 0.13404438 , 0.77967281 , 0.78480563] ,
      [ 0.62687607, 0.51112285, 0.18374991, 0.2582663 , 0.58475672],
      [ 0.72768256, 0.08885194, 0.69519174, 0.16049876, 0.34557215],
      [0.93724333, 0.17407127, 0.1237831, 0.96840203, 0.52790012]])
```

Numpy - 파일로 부터 읽어오기

```
>>> birth = np.genfromtxt('births.csv', delimiter=',', skip header=1)
>>> birth
array([[1.96900e+03, 1.00000e+00, 1.00000e+00, nan, 4.04600e+03],
      [1.96900e+03, 1.00000e+00, 1.00000e+00, nan, 4.44000e+03],
      [1.96900e+03, 1.00000e+00, 2.00000e+00, nan, 4.45400e+03],
      [2.00800e+03, 1.10000e+01,
                                      nan,
                                                  nan, 1.65468e+05],
      [2.00800e+03, 1.20000e+01,
                                                 nan, 1.73215e+05],
                                       nan,
      [2.00800e+03, 1.20000e+01,
                                      nan,
                                                 nan, 1.81235e+05]])
>>> np.savetxt('births.txt', birth) # 텍스트 포멧으로 저장
>>> np.save('saved-matrix.npy', birth) # numpy 포멧으로 저장
>>> np.load('saved-matrix.npy')
array([[1.96900e+03, 1.00000e+00, 1.00000e+00, nan, 4.04600e+03],
      [1.96900e+03, 1.00000e+00, 1.00000e+00, nan, 4.44000e+03],
      [1.96900e+03, 1.00000e+00, 2.00000e+00, nan, 4.45400e+03],
                                                 nan, 1.65468e+051,
      [2.00800e+03, 1.10000e+01,
                                      nan,
      [2.00800e+03, 1.20000e+01,
                                                  nan, 1.73215e+05],
                                      nan,
      [2.00800e+03, 1.20000e+01,
                                                  nan, 1.81235e+05]])
                                      nan,
```

Numpy - ndarray

- NumPy's main object is the homogeneous multidimensional array called n darray.
 - This is a table of elements (usually numbers), all of the same type, indexed by a tuple of positive integers. Typical examples of multidimensional arrays includ e vectors, matrices, images and spreadsheets.
 - Dimensions usually called axes, number of axes is the rank

Numpy - ndarray attributes

❖ ndarray.ndim

■ 차원(dimensions) 수

ndarray.shape

■ row, column의 개수를 tuple 로 반환, (# of rows, # of columns)

ndarray.size

■ 요소의 개수, # of rows x # of columns

ndarray.dtype

• type, 예) bool_, character, int_, int8, int16, int32, int64, float_, float8, float16, float32, float64, complex _, complex64, object_.

ndarray.itemsize (ndarray.dtype.itemsize)

■ 요소의 byte 크기, 예) float64 - 8 (=64/8), complex32 - 4

ndarray.data

■ 요소를 담고 있는 buffer(memory)

Numpy - 복사

```
>>> x = np.array([1,2,3,4])
>>> y = x
>>> x is y
True
>>> id(x), id(y)
(139814289111920, 139814289111920)
>>> x[0] = 9
>>> V
array([9, 2, 3, 4])
>>> x[0] = 1
>>> z = x[:]
>>> x is z
False
>>> id(x), id(z)
(139814289111920, 139814289112080)
>>> x[0] = 8
>>> z
array([8, 2, 3, 4])
```

```
>>> x = np.array([1,2,3,4])
>>> y = x.copy()
>>> x is y
False
>>> id(x), id(y)
(139814289111920, 139814289111840)
>>> x[0] = 9
>>> x
array([9, 2, 3, 4])
>>> y
array([1, 2, 3, 4])
```

Numpy - 연산자

```
>>> a = np.arange(4.0)
>>> b = a * 23.4
>>> c = b/(a+1)
>>> c += 10
>>> print c
[ 10. 21.7 25.6 27.55]
>>> arr = np.arange(100, 200)
>>> select = [5, 25, 50, 75, -5]
>>> print(arr[select]) # index로 가져오기 - integer lists
[105, 125, 150, 175, 195]
>>> arr = np.arange(10, 20)
>>> div by 3 = arr %3 == 0
>>> print(div by 3)
[ False False True False False True False]
>>> print(arr[div_by_3])  # boolean lists
[12 15 18]
>>> arr = numpy.arange(10, 20).reshape((2,5))
[[10 11 12 13 14]
 [15 16 17 18 19]]
```

Numpy - 연산함수

```
>>> arr.sum()
145
>>> arr.mean()
14.5
                                 ❖ 대부분의 array method는 동일한 함수를 가지고 있음
>>> arr.std()
2.8722813232690143
                                      >>> arr.sum()
>>> arr.max()
                                      45
19
                                      >>> np.sum(arr)
>>> arr.min()
                                      45
10
>>> div by 3.all()
False
>>> div by 3.any()
True
>>> div_by_3.sum()
>>> div by 3.nonzero()
(array([2, 5, 8]),)
```

Numpy - 정렬

```
\Rightarrow \Rightarrow arr = np.array([4.5, 2.3, 6.7, 1.2, 1.8, 5.5])
>>> arr.sort() # array 자체 정렬
>>> print(arr)
[ 1.2 1.8 2.3 4.5 5.5 6.7]
>>> x = np.array([4.5, 2.3, 6.7, 1.2, 1.8, 5.5])
>>> np.sort(x) # 정렬된 array 반환
array([ 1.2, 1.8, 2.3, 4.5, 5.5, 6.7])
>>> print(x)
[ 4.5 2.3 6.7 1.2 1.8 5.5]
>>> s = x.argsort() # 정렬된 index 반환
>>> s
array([3, 4, 1, 0, 5, 2])
>>> x[s]
array([ 1.2, 1.8, 2.3, 4.5, 5.5, 6.7])
```

Numpy - 배열연산

```
>>> a = np.array([[1.0, 2.0], [4.0, 3.0]])
>>> print(a)
[[ 1. 2.]
[ 3. 4.]]
>>> a.transpose() # 전치 행렬
array([[ 1., 3.],
      [ 2., 4.]])
>>> u = np.eye(2) # 대각 행렬
>>> u
array([[ 1., 0.],
     [ 0., 1.]])
>>> j = np.array([[0.0, -1.0], [1.0, 0.0]])
>>> np.dot (j, j) # matrix product
array([[-1., 0.],
      [ 0., -1.]])
```

Numpy - 기초통계

❖ 평균, 분산, 표준편차 등의 기초 통계

```
>>> a = np.array([1, 4, 3, 8, 9, 2, 3], float)
>>> np.median(a)
3.0
```

❖ 상관계수

❖ 공분산 행렬

Numpy - arrays, matrices

```
>>> m = np.mat([[1,2],[3,4]])
>>> a = np.array([[1,2],[3,4]])
>>> m = np.mat(a)
>>> a = np.array([[1,2],[3,4]])
>>> m = np.asmatrix(a)
>>> a[0, 0] = 100
>>> print(a)
[[100 2]
[3 4]]
>>> print(m)
[[100 2]
 [3 4]]
```

Numpy - matrices

```
>>> a = array([[1,2],[3,4]])
>>> m = mat(a)
>>> m = matrix([[1, 2], [3, 4]])
>>> a[0]
array([1, 2])
>>> m[0]
matrix([[1, 2]])
>>> a*a
array([[ 1, 4], [ 9, 16]])
>>> m*m
        # np.dot
matrix([[ 7, 10], [15, 22]])
>>> a**3
array([[ 1, 8], [27, 64]])
>>> m**3
matrix([[ 37, 54], [ 81, 118]])
>>> m.T
matrix([[1, 3], [2, 4]])
>>> m.H
matrix([[1, 3], [2, 4]])
>>> m.I
matrix([[-2., 1.], [ 1.5, -0.5]])
```

Numpy - array수학연산

```
>>> a = np.array([1,2,3], float)
>>> b = np.array([5,2,6], float)
>>> a + b
array([6., 4., 9.])
>>> a - b
array([-4., 0., -3.])
>>> a * b
array([5., 4., 18.])
>>> b / a
array([5., 1., 2.])
>>> a % b
array([1., 0., 3.])
>>> b**a
array([5., 4., 216.])
>>> a = np.array([[1, 2], [3, 4], [5, 6]], float)
>>> b = np.array([-1, 3], float)
>>> a + b
array([[ 0., 5.],
    [ 2., 7.],
       [ 4., 9.]])
```

```
>>> a = np.array([[1, 2], [3, 4]
, [5, 6]], float)
\Rightarrow > b = np.array([-1, 3], float)
>>> a * a
array([[ 1., 4.],
   [ 9., 16.],
     [ 25., 36.]])
>>> b * b
array([ 1., 9.])
>>> a * b
array([[ -1., 6.],
     [-3., 12.],
      [-5., 18.]
```

Numpy - array수학연산

```
>>> A = np.array([[n+m*10 for n in range(5)] for m in range(5)])
>>> v1 = arange(0, 5)
>>> A
array([[ 0, 1, 2, 3, 4],
[10, 11, 12, 13, 14],
[20, 21, 22, 23, 24],
[30, 31, 32, 33, 34],
[40, 41, 42, 43, 44]])
>>> v1
array([0, 1, 2, 3, 4])
>>> np.dot(A, A)
array([[ 300, 310, 320, 330, 340],
      [1300, 1360, 1420, 1480, 1540],
      [2300, 2410, 2520, 2630, 2740],
       [3300, 3460, 3620, 3780, 3940],
       [4300, 4510, 4720, 4930, 5140]])
>>>
>>> np.dot(A,v1)
array([ 30, 130, 230, 330, 430])
>>> np.dot(v1,v1)
30
```

Numpy - array수학연산

```
>>> M = np.matrix(A)
>>> v = np.matrix(v1).T
>>> v
matrix([[0],
        [1],
        [2],
        [3],
        [4]])
>>> M*v
matrix([[ 30],
       [130],
       [230],
        [330],
       [430]])
>>> v.T * v # inner product
matrix([[30]])
# standard matrix algebra applies
>>> v + M*v
matrix([[ 30],
       [131],
        [232],
        [333],
        [434]])
```

Pandas -데이터가져오기

```
#Read csv file
df = pd.read_csv("http://rcs.bu.edu/examples/python/data_analysis/Salaries.csv ")
```

```
pd.read_excel('myfile.xlsx', sheet_name='Sheet1)
pd.read_stata('myfile.dta')
pd.read_sas('myfile.sas7bdat')
pd.read_hdf('myfile.h5','df')
```

https://pandas.pydata.org/pandas-docs/stable/reference/io.html

Pandas - Data Frame data types

Pandas Type	Native Python Type	Description
object	string	컬럼 데이터가 숫자와 문자가 혼합된 데이터의 경우 object로 자동 매핑
int64	int	정수(64는 메모리의 크기)
float64	float	부동소수점숫자, 컬럼 데이터가 숫자와 NaN으로 구성되어 있으면 float64로 매핑
datetime64, timedelta[ns]	N/A	날짜, 시간

Pandas - Data Frame data types

```
#Check a particular column type
In [4]:
          df['salary'].dtype
Out[4]: dtype('int64')
          #Check types for all the columns
In [5]:
          df.dtypes
Out[4]:
          rank
                       object
                       object
          discipline
          phd
                       int64
                       int64
          service
                       object
          sex
          salary
                       int64
          dtype: object
```

Pandas – Data Frames attributes

속성	설명
dtypes	컬럼들의 type list 반환
columns	컬럼들의 이름 list 반환
axes	로우, 컬럼 정보 list 반환
ndim	차원 정보 반환
size	요소들의 개수 반환
shape	차원수에 대한 tuple 반환
values	Data 들을 numpy array로 반환

Pandas - Data Frames methods

함수	설명
head([n]), tail([n])	처음/마지막 n개의 행
describe()	숫자 데이터에 대한 기술 통계량 산출
max(), min()	모든 숫자 컬럼에 대한 최대/최소 값 반환
mean(), median()	모든 숫자 컬럼에 대한 평균/중앙 값 반환
std()	모든 숫자 컬럼에 대한 표준편차 반환
sample([n])	임의의 샘플 데이터 반환
dropna()	NA 값이 들어 있는 모든 행 삭제

Data Frames *groupby* method

- 데이터를 특정 조건에 의해 몇 개의 그룹으로 나눔
- 각 그룹에 대한 통계량 계산

```
In [ ]: #Group data using rank
         df rank = df.groupby(['rank'])
In []: #Calculate mean value for each numeric column per each group
         df rank.mean()
                phd
                       service salary
         rank
         AssocProf 15.076923 11.307692 91786.230769
          AsstProf 5.052632 2.210526 81362.789474
             Prof 27.065217 21.413043 123624.804348
In [ ]: | #Calculate mean salary for each professor rank:
         df.groupby('rank')[['salary']].mean()
                salary
         AssocProf 91786.230769
          AsstProf 81362.789474
             Prof 123624.804348
```

Pandas - Data Frames *groupby* method

동작 방식:

- Lazy evaluation : groupby를 실행하면 grouping 조건에 대한 적합성 여부만 판단하고 실제 grouping은 필요한 시점에 이루어 짐
- grouping 동작이 일어나면 key에 대한 sorting 이 수행됨, 실행 속도를 향상 하려면 "s ort=False" 파라메터를 지정

```
In []: #Calculate mean salary for each professor rank:
    df.groupby(['rank'], sort=False)[['salary']].mean()
```

Pandas – Data Frame: filtering

```
In []: #Calculate mean salary for each professor rank:
    df_sub = df[df['salary'] > 120000]
```

- greater
- \ less
- == equal

- >= greater or equal;
- <= less or equal;</p>
- != not equal;

```
In []: #Select only those rows that contain female professors:
    df_f = df[df['sex'] == 'Female']
```

Pandas - Data Frames: Slicing

```
In [ ]: #Select column salary:
                                                                             Series
        df['salary']
In [ ]: #Select column salary:
                                                                             DataFrame
        df[['rank','salary']]
In []: #Select rows by their position:
        df[10:20]
In []: #Select rows by their labels:
        df.loc[10:20,['rank','sex','salary']]
              rank sex salary
           10 Prof Male 128250
Out[]:
           11 Prof Male 134778
           13 Prof Male 162200
           14 Prof Male 153750
           15 Prof Male 150480
              Prof Male 150500
```

Pandas – Data Frames: Sorting

```
In []: # Create a new data frame from the original sorted by the column Salary
          df sorted = df.sort values( by ='service')
          df sorted.head()
              rank discipline phd service
Out[]:
                                  sex salary
          55 AsstProf
                                0 Female 72500
          23 AsstProf
                                0 Male 85000
          43 AsstProf
                              0 Female 77000
         17 AsstProf
                       B 4
                                0 Male 92000
                       B 1
          12 AsstProf
                                0 Male 88000
In [ ]: | df_sorted = df.sort_values( by =['service', 'salary'], ascending = [True, False])
          df sorted.head(10)
               rank discipline phd service
                                     sex salary
Out[]: 52
                       A 12
                                0 Female 105000
          17 AsstProf
                       B 4
                                         92000
          12 AsstProf
                       B 1
                                0 Male
                                         88000
                       A 2
          23 AsstProf
                                         85000
          43 AsstProf
                                0 Female 77000
          55 AsstProf
                       A 2
                                0 Female 72500
          57 AsstProf
                       A 3
                                1 Female 72500
          28 AsstProf
                                 2 Male
                                         91300
                                 2 Female
          42 AsstProf
                                         80225
                                                      <u>37</u>
          68 AsstProf
                                 2 Female 77500
```

Pandas – Missing Values

```
In [ ]: # Read a dataset with missing values
          flights = pd.read csv("http://rcs.bu.edu/examples/python/data analysis/flights.csv")
In []: # Select the rows that have at least one missing value
          flights[flights.isnull().any(axis=1)].head()
Out[]:
             year month day dep_time dep_delay arr_time arr_delay carrier tailnum flight origin dest air_time distance hour minute
          330 2013
                            1807.0
                                     29.0
                                          2251.0
                                                         UA N31412 1228
                                                                       EWR SAN
                                                                                  NaN
                                                                                         2425 18.0
                                                                                                   7.0
          403 2013
                              NaN
                                     NaN
                                            NaN
                                                   NaN
                                                         AA N3EHAA
                                                                   791
                                                                        LGA DFW
                                                                                  NaN
                                                                                         1389
                                                                                             NaN
                                                                                                   NaN
          404 2013
                                                         AA N3EVAA 1925
                                                                       LGA MIA
                              NaN
                                     NaN
                                            NaN
                                                   NaN
                                                                                  NaN
                                                                                         1096
                                                                                            NaN
                                                                                                   NaN
          855 2013
                     1 2
                            2145.0
                                                                  1299
                                                                       EWR RSW
                                                                                         1068
                                     16.0
                                            NaN
                                                   NaN
                                                         UA N12221
                                                                                  NaN
                                                                                             21.0
                                                                                                   45.0
          858 2013
                     1 2
                              NaN
                                     NaN
                                            NaN
                                                   NaN
                                                              NaN 133
                                                                        JFK LAX
                                                                                  NaN
                                                                                         2475 NaN
                                                                                                   NaN
```

Pandas - Missing Values

함수	설명
dropna()	NA 값이 하나라도 들어 있는 모든 행 삭제
dropna(how='all')	모든 값이 NA인 행 삭제
dropna(axis=1, how='all')	모든 값이 NA인 열 삭제
dropna(thresh = 5)	NA값이 5개 이하로 들어 있는 행 삭제
fillna(0)	NA 값을 0으로 채움
isnull()	값이 NA이면 True 반환
notnull()	값이 NA가 아니면 True 반환

Pandas – Missing Values

pd.read_xxx:

■ na_values : NA/NaN으로 인식할 값 지정

■ keep_default_na : 데이터를 파싱할 때 기본 NA 값을 포함할지 여부

■ na_filter: NA 파싱 여부

na_values	keep_default_na	동작
not None	True	지정된 na_values 값이 기본 NA 값과 함께 NA로 인식
None	True	기본 NA 값만 NA로 인식
not None	False	기본 NA 값만 NA로 인식
None	False	모든 값이 NA로 인식 안됨

❖ na_filter 가 False이면 na_values, keep_default_na 값이 무시됨

Pandas – Missing Values

- 합계를 구할 때는 missing value는 0으로 취급
- 모든 값이 missing value이면 합계는 NaN
- cumsum(), cumprod() 실행할 때, missing values는 무시되지만, 결과에는 남아 있음
- GroupBy를 실행할 때 missing values는 제외 됨
- 대부분의 기술 통계 함수는 "*skipna*" 파라메터를 가지고 있어서 missing value를 제외할 지 여부를 결정. 기본값은 True

Pandas – Aggregation Functions in Pandas

Aggregation - 각 그룹에 대한 요약 통계

- compute group sums or means
- compute group sizes/counts

aggregation functions:

- min, max
- count, sum, prod
- mean, median, mode, mad
- std, var

Pandas – Basic Descriptive Statistics

함수	설명
describe	기본 통계량 (count, mean, std, min, quantiles, max)
min, max	값의 최소 / 최대값
mean, median, mode	평균, 중앙값, 최빈값
var, std	분산, 표준편차
sem	편향되지 않은 표준 오류
skew	편향되지 않은 비대칭도(왜도)
kurt	첨도