데이터 분석(Python / R) 통계분석 기초


삼성전자공과대학교 3학년 3학기

		Features			
		Two group	Multiple Group	One Variable	Multiple Variable
Target Variable	Number	T test	ANOVA	Linear regression	Multiple linear regression
	Category	Chi square Test		Logistic regression	

Correlation(상관계수) vs. Covariance(공분산)

$$cov(x, y) = \frac{\sum_{i=1}^{n} (x_i - \overline{X})(y_i - \overline{Y})}{n-1}$$

■ 공분산은 X의 편차와 Y의 편차를 곱한 것의 평균




- cov(X,Y) > 0X and Y are positively correlated
- cov(X,Y) < 0
 X and Y are inversely correlated
- cov(X,Y) = 0 X and Y are independent


$$r = \frac{\text{cov}\,ariance(x, y)}{\sqrt{\text{var}\,x}\sqrt{\text{var}\,y}}$$

- 공분산은 단위의 영향을 받음
- 공분산을 scaling
- -1 <= 상관계수 <= 1


Scatter plot of correlation coefficient




Linear correlation




Curvilinear relationships




Linear correlation






Linear correlation




Normal Distribution(정규 분포)




8

Normal Distribution(정규 분포)




9

Chi-Square Distribution




- k개의 샘플 데이터 제곱의 합의 분포
- 범주형 자료에 대한 적합성 검정
- 복수 집단에 대한 독립성 검정
- k: 자유도
- 자유도가 커지면 분포의 모양이 대칭에 가까워짐

T Distribution




- 정규분포와 후사한 분포로 t=0에 대해서 종 모양으로 대칭
- 모표준편차를 알 수 없고 표본크기가 작은 경우(n < 30)에 평균 차이 추정
- df: 자유도 (표본개수 1) 자유도가 커지면 정규분포와 유사


F Distribution



- 두 모집단의 분산에 대한 비의 추정
- 분산분석(ANOVA)과 회귀분석(Regression)의 통계적 기준
- d1, d2 : 자유도
- d1 : 집단수 1
- d2 : 표본수 -1

Interval Estimation(구간 추정)





통계적 가설 검정(Statistical Hypothesis Test)


- T-Test : 두 개의 집단간의 차이(평균)가 의미가 있는지 확인
 - 두 개의 집단 간의 평균 비교 : 남자와 여자의 소득 비교
 - 하나의 집단에 대한 비교 : 과외를 하기 전과 후의 성적 변화
 - 특정 집단의 평균이 어떤 숫자와 같은지 다른지 비교
- ANOVA-Test(ANalysis Of VAriance; 분산 분석) : 여러 그룹간(2개 이상)의 평균의 차이가 통계적으로 유의미 한지를 판단
 - 정규성 : 각각의 그룹에서 변인은 정규분포.
 - 분산의 동질성 : Y의 모집단 분산은 각각의 모집단에서 동일.
 - 관찰의 독립성: 각각의 모집단에서 크기가 각각인 표본들이 독립적으로 표집
- Chisquare-Test : 그룹간에 차이가 있는지의 여부에 대해 Chisquare분포를 사용하는 가설검정
 - 그룹간에 비율(proportion) 차이가 있는지의 여부

Linear regression

In correlation, the two variables are treated as equals. In regression, one variable is considered independent (=predictor) variable (X) and the other the dependent (=outcome) variable Y.

What is "Linear"?

- Remember this:
- Y=mX+B?



What's Slope?

A slope of 2 means that every 1-unit change in X yields a 2-unit change in Y.

Prediction


If you know something about X, this knowledge helps you predict something about Y. (Sound familiar?...sound like conditional probabilities?)

Regression equation

Expected value of y at a given level of x=

$$E(y_i / x_i) = \alpha + \beta x_i$$


Predicted value for an individual...




Assumptions (or the fine print)

- Linear regression assumes that...
 - -1. The relationship between X and Y is linear
 - −2. Y is distributed normally at each value of X
 - -3. The variance of Y at every value of X is the same (homogeneity of variances)
 - -4. The observations are independent

The standard error of Y given X is the average variability around the regression line at any given value of X. It is assumed to be equal at all values of X.



Regression Picture



*Least squares estimation gave us the line (β) that minimized C^2

 $R^2 = SS_{reg}/SS_{total}$

$$\sum_{i=1}^{n} (y_i - \overline{y})^2 = \sum_{i=1}^{n} (\hat{y}_i - \overline{y})^2 + \sum_{i=1}^{n} (\hat{y}_i - y_i)^2$$

 A^2

SS_{total}

Total squared distance of observations from naïve mean of y

Total variation

 \mathbf{B}^2

SSre

Distance from regression line to naïve mean of y Variability due to x (regression)

 \mathbb{C}^2

SSresidue

Variance around the regression line


Additional variability not explained by x—what least squares method aims to minimize

Recall example: cognitive function and vitamin D

- Hypothetical data loosely based on [1]; cross-sectional study of 100 middle-aged and older European men.
 - Cognitive function is measured by the Digit Symbol Substitution Test (DSST).

1. Lee DM, Tajar A, Ulubaev A, et al. Association between 25-hydroxyvitamin D levels and cognitive performance in middle-aged and older European men. J Neurol Neurosurg Psychiatry. 2009 Jul;80(7):722-9.

Distribution of vitamin D




Distribution of DSST

Normally distributed

Mean = 28 points


Standard deviation = 10 points




Four hypothetical datasets

- I generated four hypothetical datasets, with increasing TRUE slopes (between vit D and DSST):
 - -0
 - 0.5 points per 10 nmol/L
 - 1.0 points per 10 nmol/L
 - 1.5 points per 10 nmol/L


Dataset 1: no relationship




Dataset 2: weak relationship



Dataset 3: weak to moderate relationship





Dataset 4: moderate relationship



Regression equation:

$$E(Y_i) = 28 + 0*vit D_i (in 10 nmol/L)$$






Note how the line is a little deceptive; it draws your eye, making the relationship appear stronger than it really is!

Regression equation:

$$E(Y_i) = 26 + 0.5*vit$$


 D_i (in 10 nmol/L)



Regression equation:

$$E(Y_i) = 22 + 1.0*vit$$

 D_i (in 10 nmol/L)



Regression equation:

 $E(Y_i) = 20 + 1.5*vit D_i$ (in 10 nmol/L)

Note: all the lines go through the point (63, 28)!

Estimating the intercept and slope: least squares estimation

** Least Squares Estimation

A little calculus....

What are we trying to estimate? β , the slope, from

What's the constraint? We are trying to minimize the squared distance (hence the "least squares") between the observations themselves and the predicted values, or (also called the "residuals", or left-over unexplained variability)

Difference_i = $y_i - (\beta x + \alpha)$ Difference_i² = $(y_i - (\beta x + \alpha))^2$

Find the β that gives the minimum sum of the squared differences. How do you maximize a function? Take the derivative; set it equal to zero; and solve. Typical max/min problem from calculus....

$$\frac{d}{d\beta} \sum_{i=1}^{n} (y_i - (\beta x_i + \alpha))^2 = 2(\sum_{i=1}^{n} (y_i - \beta x_i - \alpha)(-x_i))$$

$$2(\sum_{i=1}^{n} (-y_i x_i + \beta x_i^2 + \alpha x_i)) = 0...$$

From here takes a little math trickery to solve for β ...

Resulting formulas ···

Slope (beta coefficient) =
$$\hat{\beta} = \frac{Cov(x, y)}{Var(x)}$$

Intercept= Calculate:
$$\hat{\alpha} = \overline{y} - \hat{\beta}\overline{x}$$


Regression line always goes through the point: (\bar{x}, \bar{y})

Relationship with correlation

$$\hat{r} = \hat{\beta} \frac{SD_x}{SD_y}$$

In correlation, the two variables are treated as equals. In regression, one variable is considered independent (=predictor) variable (X) and the other the dependent (=outcome) variable (X).

Example: dataset 4



SDx = 33 nmol/L

SDy= 10 points

Cov(X,Y) = 163points*nmol/L

Beta = $163/33^2 = 0.15$ points per nmol/L

= 1.5 points per 10 nmol/L

$$r = 163/(10*33) = 0.49$$

Or

$$r = 0.15 * (33/10) = 0.49$$

Residual Analysis: check assumptions

$$e_i = Y_i - \hat{Y}_i$$

- The residual for observation i, e_i, is the difference between its observed and predicted value
- Check the assumptions of regression by examining the residuals
 - Examine for linearity assumption
 - Examine for constant variance for all levels of X (homoscedasticity)
 - Evaluate normal distribution assumption
 - Evaluate independence assumption
- Graphical Analysis of Residuals
 - Can plot residuals vs. X


Predicted values...

$$\hat{y}_i = 20 + 1.5x_i$$

For Vitamin D = 95 nmol/L (or 9.5 in 10 nmol/L):

$$\hat{y}_i = 20 + 1.5(9.5) = 34$$

Residual = observed - predicted




$$y_i = 48$$


$$\hat{y}_i = 34$$

$$y_i - \hat{y}_i = 14$$


Residual Analysis for Linearity




Residual Analysis for Homoscedasticity




Residual Analysis for Independence






Residual plot, dataset 4




Multiple linear regression ···

- What if age is a confounder here?
 - Older men have lower vitamin D
 - Older men have poorer cognition
- "Adjust" for age by putting age in the model:
 - DSST score = intercept + slope₁xvitamin D + slope₂ xage


2 predictors: age and vit D…



Different 3D view ···



Fit a plane rather than a line...



On the plane, the slope for vitamin D is the same at every age; thus, the slope for vitamin D represents the effect of vitamin D when age is held constant.

Equation of the "Best fit" plane ...

- DSST score = 53 + 0.0039xvitamin D (in 10 nmol/L) 0.46 xage (in years)
- P-value for vitamin D >>.05
- P-value for age <.0001
- Thus, relationship with vitamin D was due to confounding by age!

Multiple Linear Regression

More than one predictor...

$$E(y) = \alpha + \beta_1 * X + \beta_2 * W + \beta_3 * Z...$$


Each regression coefficient is the amount of change in the outcome variable that would be expected per one-unit change of the predictor, if all other variables in the model were held constant.

A t-test is linear regression!

- Divide vitamin D into two groups:
 - Insufficient vitamin D (<50 nmol/L)
 - Sufficient vitamin D (>=50 nmol/L), reference group
- We can evaluate these data with a t-test or a linear regression...

$$T_{98} = \frac{40 - 32.5 = 7.5}{\sqrt{\frac{10.8^2}{54} + \frac{10.8^2}{46}}} = 3.46; p = .0008$$

As a linear regression...



Slope represents the difference in means between the groups. Difference is significant.


ANOVA is linear regression!


- Divide vitamin D into three groups:
 - Deficient (<25 nmol/L)</p>
 - Insufficient (>=25 and <50 nmol/L)</p>
 - Sufficient (>=50 nmol/L), reference group

DSST= α (=value for sufficient) + $\beta_{\text{insufficient}}^*$ (1 if insufficient) + β_2^* (1 if deficient)

This is called "dummy coding"—where multiple binary variables are created to represent being in each category (or not) of a categorical variable

The picture…





Results...

Parameter Estimates

	Parar	neter Star	ndard		
Variable	DF	Estimate	Error	t Value	Pr > t
Intercept	1	40.07407	1.47817	27.11	<.0001
deficient	1	-9.87407	3.73950	-2.64	0.0096
insufficient	1	-6.87963	2.33719	-2.94	0.0041

- Interpretation:
 - The deficient group has a mean DSST 9.87 points lower than the reference (sufficient) group.
 - The insufficient group has a mean DSST 6.87 points lower than the reference (sufficient) group.

Multivariate regression pitfalls

Multi-collinearity

Residual confounding

Overfitting

Multicollinearity

• Multicollinearity arises when two variables that measure the same thing or similar things (e.g., weight and BMI) are both included in a multiple regression model; they will, in effect, cancel each other out and generally destroy your model.

Model building and diagnostics are tricky business!

Residual confounding

 You cannot completely wipe out confounding simply by adjusting for variables in multiple regression unless variables are measured with zero error (which is usually impossible).

Overfitting


- In multivariate modeling, you can get highly significant but meaningless results if you put too many predictors in the model.
- The model is fit perfectly to the quirks of your particular sample, but has no predictive ability in a new sample.

R-Square(결정 계수)


$$R^2 = 1 - \frac{\Sigma(\ \, ^2 \Sigma^2 \,\,)}{\Sigma(\ \, ^2 \Xi^2 \,\,)}$$

오차 = $(t_i - y_i)$, t_i :실제값 , y_i :예측값
편차 = $(t_i - \overline{t_i})$, t_i :실제값 , $\overline{t_i}$:평균값

$$R^2=rac{\Sigma(\ ext{od=} x ext{od} \ ext{cd} \ ext{cd}}{\Sigma(\ ext{dd} x^2\)}$$
 예측값에 대한 편차 = $(y_i-\overline{t_i}\)$, y_i :예측값 , $\overline{t_i}$:평균값 편차 = $(t_i-\overline{t_i}\)$, t_i :실제값 , $\overline{t_i}$:평균값



R-Square(결정 계수)



R-Square(결정 계수)

총 변동 Total SS: total sum of squares (SST):

$$SST = \sum_{i=1}^{n} (y_i - \bar{y})^2.$$
: 개별 y의 편차제곱의 합

설명된 변동 Model SS :explained sum of squares (SSE) : $SSE = \sum_{i=1}^{n} (\hat{y}_i - \bar{y})^2.$: 회귀식 추정 y의 편차제곱의 합

설명 안된 변동 Residual SS : residual sum of squares (SSR) : $SSR = \sum_{i=1}^{n} \hat{u}_{i}^{2}$: 잔차의 제곱의 합

$$\frac{\sum (\,\widehat{Y}_i \! - \overline{Y})^2}{\sum (\,Y_i \! - \overline{Y})^2} \! = r^2$$

$$R^2 \equiv SSE/SST = 1 - SSR/SST.$$

Adjusted R-Square(수정된 결정계수)

■ 결정계수는 독립변수 개수가 많아질수록 그 값이 커지게 되어 종속변수의 변동을 별로 설명해 주지 못하는 변수가 모형에 추가된다고 하더라도 결정계수값이 커질 수 있음

adjusted
$$R^2 = 1 - \frac{n-1}{(n-p-1)(1-R^2)}$$

n: 표본 데이터에서 자료의 개수

p: 독립 변수의 개수; 모형에서 사용한 상수를 제외한 변수의 개수

F-Statistics(F 검정 통계량)

F-Test : F-검정은 두 모집단의 분산의 차이가 있는가를 검정할 때 사용

n 개의 관측치와 p 개의 독립변수에 대한 다중회귀분석

- 귀무가설(H0): β1=β2=···=βp=0 즉, 모든 독립변수가 종속변수과 관계 없다.
- 대립가설(H1): β1,β2,···,βp 중 적어도 하나는 00 이 아니다. 즉, 종속변수와 관계 있는 독립변수가 존재한다

$$F = rac{ ext{SSR}/p}{ ext{SSE}/(n-p-1)}$$
 는 자유도가 $(p,n-p-1)$ 인 F분포를 따른다.

n 개의 관측치와 p 개의 독립변수에 대한 다중회귀분석에서 전체모형 FM이라고 하고, FM에서 k 개의 독립변수가 제거된 모형을 축소모형 RM

- 귀무가설(H0) : RM 이면 충분
- 대립가설(H1) : FM이 더 좋은 모델

$$F = rac{[ext{SSR}(RM) - ext{SSR}(FM)]/(p+1-k)}{ ext{SSE}(FM)/(n-p-1)}$$
 는 자유도가 $(p+1-k,n-p-1)$ 인 F분포를 따른다.

모델 간 비교에 사용 : 첫번째 F <= 두번째 F, RM 사용 가능

T-Statistics (T 검정 통계량)

- n 개의 관측치와 p 개의 독립변수에 대한 다중회귀분석
- 귀무가설(H0): β1=0 즉, 독립변수와 종속변수는 관계 없다.
- 대립가설(H1): β1!=0 즉, 독립변수는 종속변수에 영향을 준다(독립변수의 회귀계수가 유의하다)

회귀계수의 추정치 \hat{eta}_i 와 표준오차 $\sec(\hat{eta}_i)$ 에 대해 $t_i=rac{\hat{eta}_i}{\sec(\hat{eta}_i)}$ 는 자유도가 n-p-1 인 t분포를 따른다.

P-Value < 0.05, 독립변수는 종속변수에 영향을 준다(독립변수의 회귀계수는 유의하다)

분석하고자 하는 대상들이 두 집단 혹은 그 이상의 집단으로 나누어진 경우에 개별 관측치들이 어느 집단에 분류될 수 있는가를 분석하고 이를 예측하는 모형을 개발하는데 사용되는 통계기법

Linear regression vs. Logistic regression

	일반선형 회귀분석	로지스틱 회귀분석
종속변수	연속형 변수	이산형 변수
모형 탐색 방법	최소자승법	최대우도법, 가중최소자승법
모형 검정	F-test, t-test	χ² test


로지스틱 회귀분석 과정


1단계: 각 집단에 속하는 확률의 추정치를 예측. 이진분류의 경우 집단 1에 속하는 확률 P(Y=1)의 추정치로 얻음.

2단계: 추정확률 → 분류기준값(cut-off) 적용 → 특정범주로 분류

예) P(Y=1) ≥ 0.5 → 집단 1로 분류

P(Y=1) (0.5 → 집단 0으로 분류





- 로짓(logit)함수: log(odds)
 - 종속변수로 Y를 사용하는 대신에 로짓함수를 사용
 - 집단 1에 속하는 확률인 p를 구한다
 - P는 [0,1]사이의 값을 갖는다
 - 그러나 만약 p를 다음의 식과 같이 q개의 예측변수들의 선형함수로 표현한다면 우변이 0과 1사이의 값을 갖는다는 것을 보장할 수 없게 됨

$$p = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_q x_q$$

따라서 다음과 같은 비선형 함수를 이용

$$p = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_q x_q)}}$$

❖ 로지스틱 반응함수(logistic response function)

$$p = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_q x_q)}}$$

- x1, x2, ··· , xq가 어떤 값을 갖는다 하더라도 우변은 항상 0과 1의 값을 갖는다
- odds(승산비)

$$odds = \frac{p}{1-p}$$

집단 1(Y=1)에 속하는 승산은 집단 1에 속하는 확률에서 집단 0에 속하는 확률을 나눈 비율

- odds
 - 사건의 odds가 주어졌을 때 사건의 확률을 계산할 수 있음

$$odds = \frac{p}{1-p} \qquad odds = e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_q x_q}$$

❤️ 로짓(logit): log(odds)

$$\log(odds) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_q X_q$$

로지스틱 회귀분석이란 로짓을 종속변수로 정의하고, 이 로짓과 q개의 예측변수와의 관계를 선형으로 모형화한 것을 말함

Maximum Likelihood Estimation(최대우도법)

- 어떤 확률변수에서 샘플링한 값들을 토대로 그 확률변수의 모수를 구하는 방법
- 즉, 어떤 모수가 주어졌을 때, 원하는 값들이 나올 가능도를 최대로 만드는 모수를 선택하는 방법
- 입력값 X와 모델의 파라메터 θ가 주어졌을 때 정답 Y가 나타날 확률을 최대화하는 θ를 찾는 것입니다. 우리가 가지고 있는 데이터가 학습 과정에서 바뀌는 것은 아니므로 X와 Y는 고정된 상태입니다.
- 모델에 X를 넣었을 때 실제 Y에 가장 가깝게 반환하는 θ를 찾아내는 것

$$egin{aligned} heta_{ML} &= arg \max_{ heta} P_{model}\left(Y|X; heta
ight) \ &= arg \max_{ heta} \sum_{i=1}^{m} \log P_{model}\left(y_{i}|x_{i}; heta
ight) \end{aligned}$$

$$\sum_{i=1}^{m} \log P_{model}(y_i|x_i;\theta) = -m \log \sigma - \frac{m}{2} \log 2\pi - \sum_{i=1}^{m} \frac{\|\hat{y}_i - y_i\|^2}{2\sigma^2}$$

AIC(Akaike Information Criterion), BIC(Bayesian Information Criterion)

$$\mathrm{AIC}_p := n \ln \left(rac{\mathrm{SSE}_p}{n}
ight) + 2(p+1) \qquad \quad \mathrm{BIC}_p := n \ln \left(rac{\mathrm{SSE}_p}{n}
ight) + (p+1) \ln n \ .$$

- p : 독립변수 개수
- 두 모형을 비교했을 때 더 작은 쪽이 더 좋다고 판단
- 변수가 많아질수록 패널티 부여

Regularization

Norm : 두 벡터 간의 거리


$$\left\|\mathbf{x}
ight\|_p := igg(\sum_{i=1}^n |x_i|^pigg)^{1/p}.$$

- * 여기서 p 는 Norm 의 차수.
- * p = 1 이면 L1 Norm 이고, P = 2 이면 L2 Norm
- * n은 해당 벡터의 원소 수
- L1 Norm : 벡터 p, q 의 각 원소들의 차이의 절대값의 합

$$d_1(\mathbf{p},\mathbf{q}) = \|\mathbf{p} - \mathbf{q}\|_1 = \sum_{i=1}^n |p_i - q_i|, ext{ where } (\mathbf{p},\mathbf{q}) ext{ are vectors } \mathbf{p} = (p_1,p_2,\ldots,p_n) ext{ and } \mathbf{q} = (q_1,q_2,\ldots,q_n)$$

L2 Norm : p, q 의 직선 거리

$$\|m{x}\|_2 := \sqrt{x_1^2 + \dots + x_n^2}.$$



Regularization

L1 Loss : 오차 절대값의 합, Least absolute deviations(LAD), Least absolute Errors(LAE), Least absolute value(LAV), Least absolute residual(LAR), Sum of absolute deviations

$$L = \sum_{i=1}^{n} |y_i - f(x_i)|$$
* y : 실제 값
* f(x) : 예측 값
* n : 데이터 개수

L2 Loss : 오차 제곱 합, Least squares error(LSE)

$$L = \sum_{i=1}^{n} (y_i - f(x_i))^2$$

- L2 Loss 는 직관적으로 오차의 제곱을 더하기 때문에 Outlier 에 더 큰 영향을 받음
- Outlier 가 적당히 무시되길 원한다면 L1 Loss 를 사용하고, Outlier 의 등장에 신경 써야 하는 경우라면 L2 Loss 를 사용
- L1 Loss 는 0인 지점에서 미분이 불가능하다는 단점 또한 가지고 있습니다.


Regularization

L1 Regularization : 기존 cost function에 가중치(weight)의 절대값을 포함하여 가중치가 너무 크지 않은 방향으로 학습되도록 함


$$Cost = \frac{1}{n} \sum_{i=1}^{n} \{L(y_i, \widehat{y}_i) + \frac{\lambda}{2} |w|\}$$
 *\lambda: learning rate

L2 Regularization: $Cost = \frac{1}{n} \sum_{i=1}^{n} \{L(y_i, \widehat{y}_i) + \frac{\lambda}{2} |w|^2\}$

A L1 regularization



B L2 regularization



* L1 Regularization은 특정 Feature

를 0으로 처리하는 것이 가능하므로

Feature selection 이 가능

Ridge, Lasso, Elastic Net Regression

- Ridge Regression : L2 Regularization 적용
 - 다중 공선성 방지
 - 계수 축소를 통한 모델 복잡도 감소
- Lasso Regression : L1 Regularization 적용
 - 변수 선택 가능, 많은 변수를 가진 데이터에 사용
- Elastic Net Regression : L1, L2 적용